

Design automation of analog and mixed-signal circuits using neural networks - A tutorial brief

Francisco Javier Gómez Pulido

28 enero 2025

Resumen

El artículo presenta una metodología para automatizar el diseño de circuitos analógicos y de señales mixtas utilizando redes neuronales artificiales (ANNs). A través de ejemplos prácticos, se demuestra cómo las ANNs pueden optimizar tareas clave, como el dimensionamiento de moduladores Sigma-Delta a nivel de sistema y el diseño de amplificadores de transconductancia operacional (OTAs) a nivel de circuito.

Se aborda el desafío de las metodologías convencionales basadas en optimización, las cuales requieren largos tiempos de simulación y múltiples iteraciones. Las ANNs se destacan por acelerar este proceso, ya sea reemplazando simuladores o actuando como motores de optimización. En los casos de estudio, las ANNs lograron mejorar significativamente la eficiencia del diseño, reduciendo el consumo de recursos computacionales y proporcionando soluciones competitivas en comparación con métodos tradicionales.

Aunque la automatización en el diseño analógico está en una etapa temprana, este enfoque basado en ANNs muestra un potencial significativo para reducir la dependencia de reglas empíricas y cerrar la brecha entre las herramientas de diseño analógico y digital. Esto posiciona a las ANNs como una herramienta clave en la evolución de la automatización del diseño electrónico.

Índice

| | | |
|----------|--|----------|
| 1 | Introducción | 3 |
| 2 | Metodología de diseño basada en optimización utilizando ANNs y técnicas de inteligencia computacional | 3 |
| 2.1 | Diseño convencional basado en optimización | 4 |
| 2.2 | Diseño basado en optimización con redes neuronales artificiales (ANNs) . | 4 |
| 3 | Diseño a nivel de sistema basado en ANNs: Aplicación a moduladores $\Sigma\Delta$ | 4 |
| 3.1 | Formulación del problema y generación del dataset | 5 |
| 3.2 | Arquitectura de redes y optimización del modelo | 5 |
| 3.3 | Ejemplos de diseño de $\Sigma\Delta$ Ms | 5 |
| 3.4 | Verificación y comparación con otros optimizadores | 6 |
| 4 | Diseño a nivel de circuito basado en ANNs: Aplicación a OTAs | 6 |
| 4.1 | Preparación del conjunto de datos para el diseño de circuitos | 6 |
| 4.2 | Definición y uso del modelo | 7 |
| 4.3 | Ejemplo de diseño de un OTA y resultados | 7 |
| 5 | Conclusiones | 7 |

1. Introducción

El desarrollo de la tecnología ha llevado a que los dispositivos electrónicos modernos se basen predominantemente en circuitos digitales, debido a su mayor eficiencia energética, programabilidad, y menor coste. A diferencia de los circuitos digitales, cuyo diseño se beneficia de herramientas avanzadas de automatización de diseño electrónico (EDA), el diseño de circuitos analógicos sigue dependiendo en gran medida de reglas empíricas y experiencia previa.

Aunque se han desarrollado diversas metodologías y herramientas EDA para automatizar el diseño de circuitos analógicos, estas estrategias suelen emplear enfoques basados en optimización, donde un simulador evalúa el rendimiento de las posibles soluciones dentro del espacio de diseño. En este contexto, los algoritmos de inteligencia artificial, especialmente las redes neuronales artificiales (ANNs), han comenzado a desempeñar un papel importante. Las ANNs pueden reemplazar simuladores o actuar como motores de optimización, automatizando el proceso de diseño y generando soluciones óptimas para especificaciones nuevas.

Este tutorial proporciona una visión general sobre la aplicación de métodos basados en ANNs al diseño automatizado de circuitos analógicos y de señales mixtas. Además, se presentan dos casos de estudio:

1. El dimensionamiento a nivel de sistema de moduladores Sigma-Delta.
2. El diseño a nivel de circuito de amplificadores de transconductancia operacional.

2. Metodología de diseño basada en optimización utilizando ANNs y técnicas de inteligencia computacional

El diseño de circuitos analógicos y de señales mixtas sigue una metodología jerárquica ampliamente utilizada, denominada enfoque de diseño descendente/ascendente. Este proceso divide el sistema en niveles de abstracción, típicamente: sistema, circuito, dispositivo y físico. A medida que las especificaciones del sistema se transmiten jerárquicamente desde el nivel superior hasta el inferior, el rendimiento se verifica en el camino inverso, del nivel inferior al superior.

En cada nivel de abstracción, se selecciona la topología o arquitectura más adecuada. Por ejemplo, en convertidores analógico-digitales (ADCs), esto implica elegir la técnica de conversión más apropiada, como pipeline o moduladores Sigma-Delta, y dentro de esta familia, seleccionar la arquitectura óptima. Una vez definida la topología, se determinan las variables de diseño necesarias para cumplir las especificaciones de cada nivel.

Este proceso de diseño suele realizarse mediante un motor de optimización, que guía un simulador para explorar el espacio de diseño y encontrar la solución óptima. Las técnicas de optimización empleadas incluyen algoritmos genéticos, recocido simulado y métodos evolutivos multiobjetivo. No obstante, estos enfoques presentan desafíos, como

largos tiempos de simulación y múltiples iteraciones requeridas para converger hacia una solución.

2.1. Diseño convencional basado en optimización

En cada nivel de abstracción del diseño, se selecciona la topología más adecuada y se determinan las variables de diseño necesarias para cumplir con las especificaciones. Por ejemplo, en moduladores Sigma-Delta, las especificaciones típicas a nivel de sistema incluyen el Número Efectivo de Bits (ENOB) y el ancho de banda (BW), los cuales se traducen en requisitos a nivel de circuito, como ganancia en corriente continua (DC), ancho de banda de ganancia (GBW) y velocidad de respuesta (SR). Estas variables de diseño a nivel de sistema se convierten en especificaciones para los niveles inferiores.

Este proceso de diseño implica múltiples iteraciones de simulación y verificación en cada nivel de abstracción. Los simuladores eléctricos, como los basados en SPICE, se utilizan para obtener alta precisión a nivel de circuito, mientras que los simuladores conductuales, como SIMSIDES, permiten una evaluación rápida a nivel de sistema mediante modelos simplificados que capturan las principales no idealidades del circuito.

2.2. Diseño basado en optimización con redes neuronales artificiales (ANNs)

Aunque los métodos convencionales de optimización son efectivos, presentan desafíos como la gran cantidad de iteraciones necesarias y los elevados tiempos de simulación. Las redes neuronales pueden mitigar estos problemas reduciendo la necesidad de simulaciones intensivas al:

- Seleccionar únicamente las soluciones más prometedoras para evaluación.
- Estimar objetivos de rendimiento del circuito, como el comportamiento en esquinas de diseño.
- Reemplazar completamente el simulador del circuito.

Además, las ANNs pueden emplearse como agentes de aprendizaje por refuerzo (RL) para optimizar circuitos, eliminando la necesidad de un bucle de optimización convencional. Este tutorial propone el uso de ANNs en un enfoque supervisado, donde se entrenan para inferir directamente los parámetros de diseño a partir de las especificaciones.

3. Diseño a nivel de sistema basado en ANNs: Aplicación a moduladores $\Sigma\Delta$

El diseño a nivel de sistema requiere resolver dos problemas fundamentales:

1. Seleccionar una arquitectura adecuada dentro de una familia de alternativas según un conjunto de especificaciones.
2. Determinar las variables de diseño óptimas que cumplan con las especificaciones para la arquitectura elegida.

Este enfoque combina redes neuronales para clasificar arquitecturas y redes de regresión para inferir las variables de diseño.

3.1. Formulación del problema y generación del dataset

El primer problema, la selección de la arquitectura, se aborda mediante un clasificador entrenado que mapea las métricas de rendimiento del sistema a una variable categórica que representa la arquitectura. El segundo problema, un problema de optimización restringida, utiliza redes neuronales de regresión entrenadas en conjuntos de datos extensos para inferir las variables de diseño que optimizan el rendimiento.

Para este enfoque, cada entrada del conjunto de datos se organiza como un triplete $\{C, \bar{s}, \bar{v}\}$, donde C es la arquitectura categórica, \bar{s} son las métricas de rendimiento del sistema, y \bar{v} las variables de diseño resultantes de simulaciones conductuales usando SIMSIDES. El conjunto de datos se normaliza para facilitar la convergencia del entrenamiento.

3.2. Arquitectura de redes y optimización del modelo

Se evaluaron diversos clasificadores, como Análisis Discriminante (QDA, LDA), Máquinas de Soporte Vectorial (SVM) y Bosques Aleatorios, siendo el Gradient Boosting el que obtuvo mejor puntuación. Para la regresión, se emplearon redes neuronales densas, y se optimizó su arquitectura mediante técnicas de Búsqueda de Arquitecturas Neuronales (NAS) usando Keras Tuner.

La precisión de las redes se evaluó en función de su capacidad para aproximar las métricas de rendimiento solicitadas. Las redes fueron usadas para generar soluciones iniciales que luego se ajustaron ligeramente para mejorar la métrica de mérito (FOM). Este proceso garantizó que las soluciones fueran óptimas para las especificaciones dadas.

3.3. Ejemplos de diseño de $\Sigma\Delta$ Ms

Se consideraron cuatro arquitecturas de moduladores Sigma-Delta como casos de estudio:

- Un modulador $\Sigma\Delta$ de 2º orden con tecnología de condensadores conmutados (SC).
- Un modulador $\Sigma\Delta$ en cascada de 3º orden (2-1 SC).
- Un modulador $\Sigma\Delta$ en cascada de 4º orden (2-1-1 SC) con cuantificación de 3 bits.
- Un modulador $\Sigma\Delta$ continuo de 2º orden basado en integradores Gm-C.

El vector de especificaciones incluyó resolución (SNR), ancho de banda (OSR) y consumo de energía (Pow). Los modelos conductuales utilizados consideraron las principales no idealidades del circuito, como ganancia limitada, ruido del amplificador y ancho de banda limitado, pero no incluyeron efectos como desajustes de dispositivos o ruido térmico.

La generación del conjunto de datos se realizó evaluando más de 200,000 diseños aleatorios, de los cuales solo aquellos con $\text{SNR} > 50\text{dB}$ fueron seleccionados para entrenamiento. El conjunto final contenía aproximadamente 120,000 elementos, que se dividieron en datos de entrenamiento, validación y prueba. El clasificador Gradient Boosting alcanzó una precisión del 93.7 % en el conjunto de validación, siendo elegido para esta tarea.

3.4. Verificación y comparación con otros optimizadores

La metodología propuesta fue validada mediante la comparación de los diseños obtenidos con ANNs frente a algoritmos de optimización convencionales, como genéticos y gradiente descendente. En un conjunto de prueba de 1000 puntos, las ANNs lograron generar diseños centrados que cumplieran con las especificaciones requeridas en al menos el 68.5 % de los casos, alcanzando hasta un 78.5 % en arquitecturas específicas.

Además, la metodología basada en ANNs mostró una mejora significativa en el tiempo de CPU, siendo al menos 60 veces más rápida que los optimizadores convencionales. También produjo diseños con menor consumo de energía y métricas competitivas, obteniendo en la mayoría de los casos mejores valores en las métricas de mérito (FOM), excepto en un caso particular.

4. Diseño a nivel de circuito basado en ANNs: Aplicación a OTAs

El diseño a nivel de circuito se centra en obtener las dimensiones y polarizaciones de los transistores para cumplir con un conjunto de especificaciones dadas. En este caso, se emplearon redes neuronales artificiales (ANNs) para predecir las variables de diseño óptimas de los amplificadores de transconductancia operacional (OTAs) en función de las especificaciones requeridas.

4.1. Preparación del conjunto de datos para el diseño de circuitos

El conjunto de datos utilizado para entrenar las ANNs incluyó pares de datos en la forma $\{\bar{s}_i, \bar{v}_i\}$, donde \bar{s}_i representa las métricas de rendimiento del circuito (como ganancia DC, ancho de banda de ganancia (GBW), consumo de corriente (I_{DD}), entre otras) y \bar{v}_i las variables de diseño, como las dimensiones y multiplicidad de los transistores. Solo se incluyeron circuitos bien diseñados en el conjunto de datos para garantizar que las predicciones fueran óptimas.

Dado que las especificaciones de diseño generalmente se expresan como desigualdades (por ejemplo, $I_{DD} < 200\mu A$), el conjunto de datos se enriqueció mediante una técnica de aumento de datos. Para cada diseño \bar{v}_i , se generaron múltiples vectores de especificaciones \bar{s}_k que eran peores (o equivalentes) que el rendimiento real del diseño \bar{v}_i . Esto permitió que las ANNs aprendieran a generalizar a un espacio de diseño más amplio. Además, el conjunto de datos fue normalizado para mejorar la eficiencia del entrenamiento.

4.2. Definición y uso del modelo

La red neuronal empleada consistió en una arquitectura densa (fully-connected) con tres capas ocultas. El conjunto de datos se dividió en un 80 % para entrenamiento y un 20 % para validación. Se usaron puntos de diseño adicionales, generados de manera independiente, para evaluar el rendimiento del modelo fuera de los datos de entrenamiento.

El modelo predijo múltiples soluciones para cada especificación objetivo \bar{s} . Estas predicciones se generaron a partir de conjuntos de especificaciones aleatorias que cumplieran con los límites definidos, lo que aumentó la cobertura del espacio de diseño y redujo posibles sesgos en los datos. Los diseños obtenidos fueron evaluados mediante simulaciones para seleccionar la solución óptima utilizando métricas como el FOM o el Pareto óptimo para analizar los compromisos entre métricas relevantes.

4.3. Ejemplo de diseño de un OTA y resultados

Como caso de estudio, se consideró un amplificador de transconductancia operacional (OTA) diseñado en tecnología CMOS de 130 nm. El conjunto de datos contenía 16,600 puntos obtenidos de optimizaciones previas, extendidos con características polinomiales de segundo orden. Las métricas utilizadas incluyeron ganancia DC, ancho de banda (GBW), consumo de corriente (I_{DD}) y margen de fase (PM).

La red neuronal utilizada tenía 14 nodos de entrada (incluyendo las características polinomiales), tres capas ocultas con 120, 240 y 60 nodos, respectivamente, y una capa de salida con 12 nodos que representaban las dimensiones de los transistores. El entrenamiento inicial en el conjunto original tomó menos de 15 minutos, seguido de un entrenamiento adicional en un conjunto aumentado de 700,000 muestras, lo que tomó 40 minutos más.

Los resultados mostraron que el modelo podía predecir tamaños de transistores que cumplieran con las especificaciones objetivo. Para cada conjunto de especificaciones, la red neuronal generó 100 predicciones con desviaciones aleatorias de hasta un 15 % de los objetivos. En todos los casos, los diseños obtenidos superaron las especificaciones requeridas o lograron FOMs mayores a 1000. Incluso cuando las especificaciones eran inviables, el modelo propuso soluciones que equilibraban las compensaciones entre métricas de rendimiento.

5. Conclusiones

El uso de redes neuronales artificiales (ANNs) para el diseño automatizado de circuitos y sistemas analógicos y de señales mixtas se ha discutido en este tutorial. La metodología presentada se ha aplicado a nivel de sistema para la síntesis de moduladores Sigma-Delta y a nivel de circuito para la optimización de amplificadores de transconductancia operacional (OTAs). Los resultados obtenidos son competitivos con otros métodos de optimización.

Aunque esta tecnología aún se encuentra en sus primeras etapas, el uso de ANNs para automatizar el diseño de circuitos y sistemas analógicos y de señales mixtas puede

contribuir a cerrar la brecha existente entre las herramientas de automatización de diseño electrónico (EDA) para circuitos digitales y analógicos.